



Universidad
Zaragoza

Trabajo Fin de Grado

**El Big Data y el análisis de datos en el mundo del
deporte (1970 - 2022)**

***Big Data and data analysis in the sports world
(1970-2022)***

Autor/es

Jesús Glaría Lorente

Director/es

Dra. Gema Martinez de Espronceda

Grado en Periodismo. Facultad de Filosofía y Letras

2022

RESUMEN

Este Trabajo de Fin de Grado tiene como objetivo principal explicar qué es y cómo funciona el Big Data en el mundo del deporte, centrándome en el fútbol. A lo largo de este documento analizaremos cómo esta tecnología ha pasado de ser utilizada por bancos y empresas de seguros, para analizar el riesgo que suponía dar préstamos a particulares o entidades, a ser responsable del éxito de diferentes entidades deportivas. Con este propósito se mostrarán ejemplos de los diferentes modelos utilizados en deportes como el béisbol, el baloncesto, el tenis o el fútbol.

Palabras clave

Big Data, Data Mining, Data Science, Análisis de datos, deporte, fútbol, tenis, baloncesto, béisbol.

ABSTRACT

The main objective of this Final Degree Project is to explain what Big Data is and how it works in the world of sport, focusing on football. Throughout this document we will analyse how this technology has gone from being used by banks and insurance companies to analyse the risk involved in lending to individuals or entities, to being responsible for the success of different sports entities. For this purpose, examples of the different models used in sports such as baseball, basketball, tennis or football will be shown.

Keywords

Big Data, Data Mining, Data Science, Data Analysis, sport, football, tennis, basketball, baseball.

ÍNDICE

1. Introducción	4
1.1 Finalidad	4
1.2 Estructura	4
1.3 Motivación	4
1.4 Metodología	5
2. Big Data y Análisis de Datos	6
2.1 Antecedentes	6
2.2 El origen de las tecnologías Big Data	7
2.3 Contexto actual	8
2.4 Qué es el Big Data y su diferencia con los datos tradicionales	10
2.5 Características del Big Data	12
2.6 Tipos de datos y análisis	12
2.7 ¿En qué se distingue un analista de un científico de datos?	14
3. El Big Data y el análisis de datos en el mundo del deporte	16
3.1 ¿Qué es la analítica deportiva?	16
3.2 Historia de la analítica deportiva	17
3.3 El análisis deportivo	19
4. Casos de éxito en la aplicación del Big Data en el mundo del deporte	20
4.1 Caso Moneyball	20
4.2 La evolución del baloncesto de Muthu Alagappan	22
4.3 El impacto del saque en el tenis	25
4.3.1 Qué se analiza durante el seguimiento	25
4.3.2 Impacto del primer y el segundo servicio	26
4.3.3 La influencia de la velocidad del servicio	26
4.3.4 Relación entre nº de golpes y porcentaje de puntos ganados	27
5. Big Data y análisis de datos en el mundo del fútbol	29
5.1 Prevención de lesiones	30
5.2 Scouting	35
5.3 Fichaje de jugadores	41
6. Conclusión	46
7. Bibliografía	47

1. Introducción

1.1 Finalidad

El objetivo de este trabajo es mostrar la importancia que ha tenido la tecnología Big Data y el análisis de datos en la evolución que han sufrido los deportes en los últimos 20 años. Para ello voy a explicar de manera simple las razones que han llevado a las diferentes entidades deportivas a incluir este método en su modelo de negocio aportando ejemplos reales.

1.2 Estructura

En primer lugar voy a explicar el origen, la evolución y la situación actual del Big Data en el panorama empresarial, explicando toda la terminología relativa al tema. En segundo lugar, voy a mostrar que aplicaciones de esta tecnología son aplicables al mundo del deporte, aportando ejemplos de casos reales en el béisbol, el baloncesto y el tenis. A continuación me voy a centrar en la utilidad que se le da a esta herramienta en el mundo del fútbol actualmente y, por último, voy a exponer mi opinión personal acerca del tema.

1.3 Motivación

He escogido este tema por dos razones. La primera es mi pasión por el fútbol y el deporte en general, lo que me ha hecho tener una actitud de interés y trabajo, ante un tema que siempre me ha generado mucha curiosidad. En segundo lugar, mi desconocimiento de la materia, ya que constantemente escucho hablar del Big Data, y del estudio de los datos sin saber realmente qué es lo que significa.

1.4 Metodología

El orden que ha seguido mi temática en el trabajo coincide con el que he seguido en mi proceso de documentación. Para poder desarrollar el tema primero realicé la lectura de un libro teórico acerca del Big Data y el análisis de datos, *La Ciencia de los Datos*, de 2019 por Herbert Jones. Además complementé esa información con la lectura de diversos artículos científicos acerca de los tipos de Big Data y de los usos que se le puede dar a esta herramienta. Una vez adquirí un conocimiento claro comencé a orientar mi búsqueda en el uso de esta tecnología en el mundo del deporte. Algunas de estas lecturas no han sido utilizadas porque enfocaban el tema desde una perspectiva que no me interesaba, pero me dieron una visión global de su uso en el mundo del deporte. Finalmente y gracias al libro *Iniciación al análisis de datos y Big Data aplicado al fútbol*, de 2017 escrito por Joaquín Roldán e Ignacio Blas, pude entender cuáles eran los usos principales en el mundo del fútbol.

2. Big Data y Análisis de Datos

2.1 Antecedentes

Para entender la aparición del término Big Data en la actualidad, tenemos que remontarnos hasta 1958 (Niño & Illarramendi, 2015, pág 1), cuando el investigador alemán de IBM Hans Peter Luhn comienza a hablar del término Business Intelligence, es decir, el análisis de los datos de un negocio en su artículo “A Business Intelligence System” publicado ese mismo año. En su publicación el bávaro definió el concepto como “ la habilidad de aprender las relaciones de hechos presentados, de forma que guíen las acciones hacia una meta deseada”.

Poco a poco los avances en la informatización de los procesos de negocio modificaron esa definición, pero ya había parecido el primer término relacionado con el análisis de datos.

Ya en los años 80 se consolida la idea de Business Intelligence gracias a propuestas como la de Howard Dresner (Lago, 2018) en las que actualizaba su definición apuntando que son “conceptos y métodos para mejorar la toma de decisiones comerciales mediante el uso de sistemas de apoyo basados en hechos”. De esta manera se comenzaron a mezclar datos que permitieran a los diferentes negocios tener una mejor visión acerca del pasado y el presente de su organización. Este tipo de análisis se conoce como descriptivo.

A este enfoque inicial, más adelante, se le añade el método de análisis predictivo, que busca extraer conocimiento de los datos por medio de patrones de conducta que permitan hacer predicciones de comportamientos futuros. Mikel Niño y Arantza Illarramendi afirman (Niño & Illarramendi, 2015, pág 1) que para denominar este tipo de interpretación de datos surge a finales de los años 80, la expresión Data Mining (minería de datos). Un término con el que se busca hacer referencia al proceso por el cual se extrae un material valioso (conocimiento). El salto cualitativo en esta práctica surge a partir de la combinación de este método de análisis con las técnicas de aprendizaje automático (Machine Learning). De esta manera se pudo comenzar a realizar modelos de predicción que en la década de los años 90 empezaron a ser aplicados principalmente en el sector bancario y de los seguros.

El empleo de minería de datos y Machine Learning sirvió, por ejemplo, para facilitarle a los bancos decidir si otorgaba a un cliente un préstamo o no.

Es gracias al Data Mining como se explica la aparición a principios de este milenio de la ciencia de datos o Data Science. Toda la información recabada mediante la minería de datos debe transformarse en conocimiento y a su vez facilitar la toma de decisiones. (VASS Team, 2018) Este concepto se desarrolló al integrar principios de otras disciplinas como las matemáticas o la estadística, que han permitido llegar al análisis de datos y a la extracción de conocimiento que tenemos actualmente.

2.2 El origen de las tecnologías Big Data

La eclosión y popularización de las páginas web entre finales de los años 90 y principios de los 2000, provocó que todas las empresas tecnológicas que trabajaban con las World Wide Web hicieran uso del Data Mining. Todas estas compañías tenían el mismo objetivo que los bancos y aseguradoras unos años antes, aprovechar sus bases de datos para potenciar su negocio. (Niño & Illarramendi, 2015, pág 1) El nacimiento de las tecnologías Big Data surge del problema que suponía analizar los grandes volúmenes de datos por medio de las técnicas tradicionales.

El principal ejemplo lo tenemos en la empresa Google, que tuvo que enfrentarse al problema de procesar su algoritmo PageRank, el cuál se aplicaba a grandes volúmenes de datos procedentes de páginas web. Ante este contratiempo, Google optó por crear su propia solución repartiendo la tarea del procesamiento de grandes volúmenes de datos. Este software conseguía simplificar enormemente el trabajo con este tipo de datos y recibió el nombre de MapReduce.

En el año 2008 los científicos informáticos, Jeffrey Dean y Sanjay Ghemawat, escribieron un artículo para la revista semanal Communications of the ACM. En aquel momento ambos eran becarios de Google y trabajaban en las instalaciones californianas de Google Mountain View. En su escrito explican la interfaz MapReduce, su modelo de programación y sus aplicaciones. Este programa se

define como “ un modelo de programación y una implementación asociada para procesar y generar grandes conjuntos de datos que se adaptan a una amplia variedad de tareas del mundo real”. (Dean & Ghemawat, 2008, pág 107) La función del sistema de ejecución de MapReduce gestiona los fallos entre las máquinas y programa la comunicación entre ellas, para hacer un uso eficiente de la red y los discos. El MapReduce supone el avance más significativo en el origen de las tecnologías Big Data.

2.3 Contexto actual

En la actualidad el Big Data ha superado todas las expectativas de crecimiento que existían hace tres décadas. Además cada gremio ha conseguido encontrar la forma de recopilar datos y sacarle una utilidad a esta tecnología para mejorar sus prestaciones, incluso sus beneficios. También ha hecho que todo tenga un aspecto mucho más empresarial, el mundo se está empezando a guiar por datos y fórmulas, antes que sentimientos o sensaciones. Aunque es cierto que en ámbitos, como el médico o el empresarial, no ha supuesto una gran revolución, en otros como en el mundo del deporte está abriendo un futuro inesperado hace 20 o 30 años.

El reputado periodista americano Kenneth Cukier (Dean & Ghemawat, 2008, pág 73) explica en una entrevista que no debemos de centrar nuestra atención en que la cantidad de datos sea muy grande, sino en que donde antes podríamos haber utilizado una técnica de muestreo para conseguir una parte de los datos, ahora mismo no es necesario ya que tenemos la capacidad de obtenerlos todos. Cukier explica que “ Eso es lo que se considera Big Data. No es necesario tener una hipótesis de antemano antes de recoger los datos. Has recogido todos los que hay, todos los datos que hay sobre un fenómeno”.

Hoy en día es obligatorio y necesario que una empresa, sea cual sea su sector, gestione de una manera adecuada sus datos para poder tomar decisiones estratégicas. Por esta razón todos los datos son válidos, y es obligación de la empresa utilizar tanto los datos relevantes como los que han sido desechados previamente, ya que hay que hacer “ un uso inteligente del mayor número de datos posible cruzando diversas y variadas fuentes”. (Roldán & Blas, 2017, pág 73)

Los usos que posee actualmente son muy variados, ya que nos puede permitir el descubrimiento de nuevos nichos de mercado, agilizar los tiempos de entrega, mejorar la variedad de productos de nuestro stock, mejorar la detección de enfermedades o incluso luchar contra el fraude o la delincuencia organizada.

El escritor Herbert Jones (Jones, 2019, pag 66-69), considera que más allá de valorar si su uso está mejorando o no nuestras vidas hay que valorar la cantidad de datos que producimos en nuestro día a día. Prácticamente a todas horas estamos dejando nuestro rastro a nivel digital tanto en comercios, como en páginas web. A pesar de que nuestros avances en los últimos 20 años han sido inmensos, todavía estamos muy lejos de sacar el rédito suficiente a esta tecnología.

Según Jones “ Uno de los mayores desafíos consiste en aprender cómo se pueden manejar nuevos tipos de datos y descubrir el tipo de información que ofrece valor a su negocio. No se trata sólo de cómo se puede acceder a nuevas fuentes de datos, sino que también son importantes las interrelaciones entre elementos y patrones. La recopilación de diferentes tipos de datos rápidamente no produce valor “. (Jones, 2019, pág 55-56)

2.4 Qué es el Big Data y su diferencia con los datos tradicionales

Existen innumerables definiciones del término Big Data. A lo largo de mi proceso de documentación he recopilado las que para mí son las más representativas.

Según Joaquín Roldán e Ignacio Blas denominamos Big Data “a la gestión y análisis de grandes volúmenes de datos estructurados, semiestructurados y no estructurados cuya obtención, recolección, gestión, tratamiento y procesamiento va más allá de lo que las herramientas más usualmente utilizadas permiten”. (Roldán & Blas, 2017, pág 66-71)

Para Herbert Jones en cambio, Big Data “se refiere a una colección de conjuntos de datos que son muy grandes y complejos, de manera que no se puede procesar utilizando herramientas de administración de bases de datos simples”. (Jones, 2019, pág 55-57)

En un artículo de la revista más grande relacionada con la computación a nivel internacional, CIO, Brian Hopkins define Big Data como “ las técnicas y tecnologías que hacen que sea económico hacer frente a los datos a una escala extrema”. Big Data trata tres cosas (Hopkins, n.d.,):

- 1) Las técnicas y la tecnología, lo que significa que la empresa tenga personal, el cuál tenga gran representación y análisis de datos para tener un valor agregado con información que no ha sido manejada.
- 2) Escala extrema de datos que supera a la tecnología actual debido a su volumen, velocidad y variedad.
- 3) El valor económico, haciendo que las soluciones sean asequibles y ayuden a la inversión en los negocios.

Por otro lado, los datos tradicionales han supuesto durante décadas la única fuente de información de las empresas acerca de sus clientes, y su competencia. Su manipulación es muy sencilla, al igual que su almacenamiento ya que son datos

estructurados, pero aportan una información más limitada y menos valiosa que la aportada por el Big Data.

Se diferencian en varios aspectos, como el tamaño. Los datos tradicionales se han medido siempre en gigabytes o terabytes, en cambio en el Big Data su tamaño y volumen se mide exabytes. En segundo lugar, la velocidad de los datos en el Big Data es mucho mayor a la de los datos tradicionales. Su aumento es tan grande que merece ser considerada como una nueva fuente de datos. Por último en el Big Data la mayor parte de los datos son semiestructurados y no estructurados. (Jones, 2019, pág 59-60)

Hay que aclarar que por qué el Big Data sea diferente a los datos tradicionales, no tiene porqué ser mejor. El poder de éste radica en el análisis y apoyo que suponen sus datos una vez publicados los resultados , pero el Big Data por sí mismo no tiene ningún valor. Es importante poder extraer una información valiosa de los datos, que nos ayude a tomar una decisión. Durante mi documentación acerca de la evolución del análisis de datos y el Big Data, me ha gustado la explicación, que aparece en el artículo del British Journal of Management, de Sasa Batistic y Paul van der Laken de cómo se le otorga valor a esa información: “ BDA (Big Data and Analytics) sólo puede añadir valor si se dispone de una infraestructura de TI (Tecnología de la Información) adecuada, si existe una cultura organizativa o si la mano de obra está suficientemente cualificada”.(Batistic & van der Laken, 2019, pág 232)

Las tecnologías Big Data ayudan a tomar decisiones importantes y son capaces de recoger grandes cantidades de datos de diferentes aspectos pero hay que ser conscientes de que la preparación de las personas que van a manipular los datos, y tener acceso a medios tecnológicos adecuados, es igual o más importante que el análisis de datos.

Un error en estos dos aspectos puede llevar a una empresa a una interpretación errónea de los datos, por eso siempre hay que “fiarse” de la información recogida pero analizar de manera objetiva esos datos, para ver si realmente tienen sentido. (Jones, 2019, pág 133-134)

2.5 Características del Big Data

Cualquier concepto existente tiene unas características propias y en este caso, el Big Data posee tres: El volumen, la variedad y la velocidad (3 V's).

El volumen hace referencia a la gran cantidad de información que debemos obtener y procesar. Cuando hablamos de variedad nos referimos a las diferentes fuentes que se utilizan para la recolección de los datos. Por último, la velocidad se refiere al tiempo utilizado en la recolección de la información, procesamiento y presentación de los resultados.

En el libro “La Ciencia de los datos” ejemplifican cada característica explicando que un buen científico de datos debe ser capaz de dominar los tres aspectos. Herbert Jones explica que el volumen es una característica diferencial porque “ las cosas adquieren una nueva dirección cuando se tienen datos gigantescos porque cada similitud se vuelve importante y uno puede sacar conclusiones falsas rápidamente”. Él mismo considera que la velocidad de los datos siempre aumenta, el ejemplo lo encontramos en el aumento de las publicaciones en diferentes redes sociales o el crecimiento en información financiera. Por último, para Jones en la variedad de datos “ Los modelos que dependen solo de un puñado de variables ahora pueden producir cientos de variables debido al aumento en el poder de cómputo”. (Jones, 2019, pág 17-19)

A estas tres facultades propias del Big Data se les pueden añadir otras que van en función del dato que se analiza cómo: la veracidad, el valor, la variabilidad, la visualización y la viabilidad. (Roldán & Blas, 2017, pág 69-70)

2.6 Tipos de datos y análisis

En un mundo en el que cada vez existen más datos debido, entre otras cosas, a la globalización, la frontera entre el fracaso y el éxito la separa la correcta interpretación de los datos. Para eso debemos ser conscientes de que existen 3 tipos en función de su formato y capacidad de almacenamiento, los datos estructurados, semiestructurados y los no estructurados. (Roldán & Blas, 2017, pág 67)

Cuando la información tiene un formato y una longitud determinada que le permite ser almacenada en tablas o bases de datos hablamos de datos estructurados. Por ejemplo una hoja excel de un centro comercial en la que aparezca nuestro nombre, la fecha de nuestra última compra, la hora y el precio.

En caso de que la información no tenga un formato determinado pero sí pueda ser almacenada hablamos de datos no estructurados. Por ejemplo una opinión en una página web, un video o un audio.

Y por último, si no puede ser almacenado y necesita de una serie de procesos informáticos para obtener la información que contiene hablamos de datos semiestructurados. Por ejemplo documentos XML o XHTML.

De la misma forma que hay variedad en la tipología de los datos, también la hay en los tipos de análisis o enfoques. A continuación vamos a explicar los tres existentes, añadiendo una serie de preguntas o ejemplos.

El primero es el enfoque descriptivo que de una manera simple podríamos definirlo como aquel que intenta responder a preguntas sobre lo que sucedió en el pasado. Por lo general si elegimos este enfoque buscamos obtener información intentando establecer relaciones entre los datos históricos y los actuales. (Jones, 2019, pág 60)

Ejemplos de preguntas:

- ¿Cuál es el jugador más efectivo desde la línea de tres puntos de la NBA?
- ¿Cuántos clientes nuevos perdió mi empresa en el segundo semestre de 2021?

En segundo lugar encontramos el enfoque predictivo el cual trata los datos de una manera determinada con el objetivo de predecir tendencias o patrones de comportamiento. De esta manera se intenta identificar los riesgos y oportunidades ante una situación. Por ejemplo, si una persona va a un banco a pedir un préstamo, la entidad posee un modelo de riesgo en el que figuran datos como saldo de cuentas bancarias, historial de impagos, préstamos en otras entidades... que determinarán si se le concede o no ese crédito, en función del valor que arroje ese cliente. (Roldán & Blas, 2017, pág 69)

El enfoque más complejo o subjetivo es el modelo prescriptivo o de decisión, mediante el cuál se busca predecir la decisión de una persona en función de la acción que lleve a cabo. Es decir se basa en el estudio de los puntos a favor y en contra de las distintas opciones. No es genérico ya que depende de cada situación y negocio.

2.7 ¿En qué se distingue un analista de un científico de datos?

Ambas profesiones existen hoy en día, y suelen ser confundidas con facilidad.

Cuando elegí este tema solía mezclar ambos conceptos, por eso he creído conveniente explicarlos y destacar sus diferencias.

Tal y como he explicado anteriormente el análisis de datos existe desde antes de la aparición del Big Data en cambio el científico de datos es una profesión que apareció a inicios de este siglo con la aparición del Big Data.

- Analista de datos

Es aquella persona capacitada en el procesamiento y análisis de los datos estadísticos. El análisis de datos le permite describir cómo usar los datos para sacar conclusiones y resolver los problemas que puedan aparecer. (Analista De Datos Y Científico De Datos: Diferencias Y Habilidades | Tecon, 2022)

En otras palabras, es quien debe determinar, una vez analizada la información, qué datos vale la pena explotar.

Debe ser capaz de manejar y descubrir conjuntos de datos y las posibles relaciones entre ellos. Debe comparar un mínimo de dos versiones de un mismo aspecto y ser capaz de valorar cuál es la más adecuada, además debe ser capaz de guiar o recomendar a una empresa basándose en las informaciones obtenidas de los conjuntos de datos analizados. (Diferencias Entre Un Científico De Datos Y Un Analista De Datos | 2022, n.d.)

- Científico de datos

Es la persona encargada de analizar cantidades de datos, estructuradas y no estructuradas para identificar patrones. (Analista De Datos Y Científico De Datos: Diferencias Y Habilidades | Tecon, 2022)

En el libro “La Ciencia de los Datos” (Jones, 2019, pág 29) se define a este profesional como “la persona que debe tener una mezcla de codificación, pensamiento crítico y capacidad estadística. Deben ser buenos en estadística y así como, en la programación”.

El científico de datos debe ser capaz de manejar un amplio conjunto de responsabilidades y ocupaciones, la principal es prever el desarrollo de por ejemplo el crecimiento de un producto, en función de la información que maneja. Debe ser capaz de anticiparse a posibles problemas que puedan surgir, además de tener que poder prestar labores de asesoría o consultoría basándose en los datos. (Diferencias Entre Un Científico De Datos Y Un Analista De Datos | 2022, n.d.)

- ¿En qué se diferencian?

Una de sus diferencias está en el alcance de su acción dentro de una empresa. El impacto de un analista de datos es menor ya que mientras él extrae, procesa, produce y diseña informes de datos, el científico analiza el modelo de negocio de toda una empresa y deduce posibles problemas. (Analista De Datos Y Científico De Datos: Diferencias Y Habilidades | Tecon, 2022)

El tamaño y el formato de la información que manejan es también diferente ya que a un analista se le entrega un paquete de datos limitado y al científico de datos un paquete desestructurado, que debe ordenar y darle sentido. (Diferencias Entre Un Científico De Datos Y Un Analista De Datos | 2022, n.d.)

Para ser más claros, al margen de estas diferencias previas, ambos deben hacer una presentación de los datos analizados, pero el científico de datos todavía debe formular conclusiones y crear un plan de acción para la entidad para la que trabaja. Básicamente el analista cumple una función de asesor o consultor, mientras que el científico está más enfocado en el proceso de creación y desarrollo de un producto.

3. El Big Data y el análisis de datos en el mundo del deporte

3.1 ¿Qué es la analítica deportiva?

Cuando escuchamos la palabra Big Data la solemos asociar con sectores científicos, comerciales o empresariales, pero en los últimos años el mundo del deporte profesional ha comenzado a utilizar esta nueva ciencia, lo que ha supuesto una revolución sin precedentes en la forma de trabajar de los profesionales. (Roldán & Blas, 2017, pág 74)

Una de las principales diferencias entre el deporte y la empresa es que, el deportista, tiene un examen cada semana, por lo que el acierto o el fracaso en la toma de sus decisiones se puede ver en un margen corto de tiempo. Esta cualidad sumada a la inmediatez de resultados que exige el deporte de élite hace que el Big Data sea una herramienta de gran utilidad.

El éxito de la utilización del análisis de datos en otros ámbitos, ha provocado que en las disciplinas deportivas el rendimiento y nivel de los deportistas no sólo sea juzgado por opiniones personales, o por el visionado de un número de vídeos, sino que actualmente su rendimiento y nivel tiene que verse reflejado por los diferentes datos recopilados sobre ellos. Renato Assunção y Konstantinos Pelechrinis en su artículo “Big Data in sports” explican que “aparte de los clubes deportivos, otras partes interesadas del sector (las oficinas de las ligas, los medios de comunicación, etc) invierten en análisis. Por ejemplo, las ligas confían cada vez más en los datos para decidir sobre posibles cambios de reglas”. (Assunção & Pelechrinis, 2018, pág 237)

Todo esto deriva en la aparición de una nueva disciplina conocida como la analítica deportiva, que consiste en investigar y modelar el rendimiento deportivo mediante técnicas científicas. Concretamente, se refiere a la gestión de datos históricos (datos biográficos, videos), el uso de modelos predictivos y sistemas de información con el objetivo de informar y guiar a los responsables en la toma de decisiones. Los datos recogidos se estandarizan, centralizan, integran y analizan utilizando diferentes métricas. Se supone que un análisis fiable y sistemático de los datos permitirá a

entrenadores, atletas y responsables políticos reforzar sus procesos de toma de decisiones. (Davenport, 2014)

3.2 Historia de la analítica deportiva




Figura 1. Un marco de análisis deportivo de trabajo. (Davenport, 2014)

La analítica deportiva ha tenido diferentes orígenes dependiendo del deporte, y la localización del mismo. En los años 60, se comenzaron a analizar los partidos por medio de anotaciones en los partidos de fútbol y baloncesto americanos. Este tipo de análisis recibió el nombre de análisis notacional y se define como “una forma objetiva de registrar el rendimiento, de modo que los acontecimientos críticos de dicho rendimiento puedan cuantificarse de forma coherente y fiable” (Hughes & Franks, 2004). Otro de los deportes que comenzó a utilizar la analítica deportiva fue el béisbol. Este deporte tiene diferentes fases durante su juego, lo que permite dividirlo en diferentes eventos. En el año 1971 se fundó la Society for American Baseball Research (SABR), una organización de miembros dedicada a fomentar la investigación y difusión de la historia y el registro por medio de las estadísticas, fundada por el periodista deportivo Bob Davids. (Society for American Baseball Research, n.d.)

Si hablamos de fútbol o soccer, el primer antecedente data de los años 50, cuando un antiguo comandante de la Real Fuerza Aérea Británica, Charles Reep comenzó a

analizar los pases que acababan en gol, incluyendo las posición del campo desde la que se realizaban. Reep fue además el autor de una de las primeras publicaciones sobre análisis deportivo (Reep & Benjamin, 1968, pág 581). Como curiosidad, a Charles Reep se le atribuye el estilo de juego del balón largo, que durante décadas ha sido la seña de identidad del fútbol anglosajón.

El problema era que esta técnica, al carecer de informatización no era efectiva ya que la recopilación y el análisis suponía mucho tiempo de trabajo. Por ejemplo, un sistema de análisis que se desarrolló para el squash, precisaba de 5 a 8 horas para controlarlo y otras 40-50 para el análisis de los datos. En la década de los años 80 la tecnología permitió la recopilación y el análisis de la información y se consiguió implementar una versión informatizada para el análisis notacional del squash. (Davenport, 2014)

El primer gran avance en el análisis deportivo sucedió en el béisbol, ya que en 1989 un profesor de biología llamado David Smith, fundó la organización sin ánimo de lucro, Retrosheet. El objetivo de la misma era el de informatizar los resultados de todos los partidos de béisbol de las grandes ligas, para poder analizar las estadísticas. Pero Smith simplemente tomó prestada la idea de Bill James, que había iniciado una aplicación llamada Scoresheet en la que publicaba los relatos de todos los partidos, jugada a jugada (Davenport, 2014). Esta colaboración fue un ejemplo para el equipo de béisbol los Atléticos de Oakland que unos años después armaron un equipo de bajo presupuesto, basándose en datos estadísticos, una historia que se popularizó gracias al libro (2003) y la película (2011) Moneyball.

Con la llegada de los años 90, el big data ya era una realidad, y comenzó a aparecer en el mundo del deporte. En el año 1995 la NBA distribuyó un software a 16 equipos de la liga llamado "Advanced Scout". Este mecanismo permitía recoger datos en bruto de los partidos, tanto de variables defensivas como ofensivas. Al final de cada partido los datos recogidos se subían a una plataforma y cada equipo podía descargarlos. Ya en el año 2003 muchos de esos datos estaban disponibles en sitios como espn.com. En el fútbol, la Premier League inglesa es la más adelantada en el uso del Big Data, aunque actualmente casi todos los equipos de las grandes ligas hacen uso de ella.

El problema es que si lo comparamos con el baloncesto, la baja frecuencia de anotación del fútbol hace que la interpretación de los datos sea menos precisa (Hughes & Franks, 2004).

3.3 El análisis predictivo

En el mundo del deporte las organizaciones deportivas no tienen intereses muy diferentes a los de otros sectores. Todas quieren crecer en el ámbito de las comunicaciones, o ser parte del proceso de globalización en el que vivimos. En la actualidad el uso de estas tecnologías está muy extendido, lo que implica que la competencia es feroz. Tal y como hemos explicado previamente, el Big Data puede ser analizado por diferentes enfoques, y en el mundo del deporte predomina el predictivo. Lo que se busca es encontrar tendencias o patrones de comportamiento a partir del análisis de resultados pasados y de esa manera poder predecir qué puede ocurrir en el futuro. (Davenport, 2014)

Más adelante voy a explicar y ejemplificar los principales usos que aporta esta tecnología, pero antes voy a nombrar algunos de ellos:

- Prevención de lesiones
- Detección de tácticas del rival y modelo de juego (scouting)
- Seguimiento de jugadores para su posible fichaje
- Elaboración de alineaciones
- Rendimiento de jugadores propios y del rival
- Análisis de los partidos

4. Casos de éxito en la aplicación del Big Data en el mundo del deporte

4.1 Caso Moneyball

Gracias al libro y a la película “Moneyball” se dió a conocer este caso que ocurrió en los años 90 en la liga profesional americana de béisbol. Los Atléticos de Oakland, uno de los equipos más pobres en ese momento, tenían como CEO a Billy Beane, un ex-jugador profesional. A pesar de contar con un presupuesto bajo, el club le exige que arme un equipo competitivo. La falta de medios económicos hace que sus mejores jugadores se marchen y se encuentra con muy pocos jugadores lo que le obliga a crear un equipo desde cero.

A pesar de que hay muchos detalles en el libro y en la película que causaron polémica ya que se consideraba que no se ceñían a la realidad, lo realmente importante es que Beane, apoyado por un profesional de la estadística armó un equipo basándose en datos que otras entidades pasaban por alto. Contra todo pronóstico los Atléticos consiguieron llegar a los playoffs. A la hora de explicar este curioso caso que revolucionó el béisbol en materia de gestión de salarios y elección de fichajes vamos a basarnos en el libro, ya que su contenido es más completo y realista que el de la película. (Lewis, 2004)

El ex-jugador profesional Billy Beane asumió el cargo de los Atléticos de Oakland en 1997. El famoso método basado en análisis de datos, se hizo efectivo en el año 2002 cuando los A's pasaron de sumar 46 victorias y 36 derrotas a 1 de julio, siendo terceros en la liga Oeste americana, a ganar la liga con 103 victorias en la temporada regular. Para situar el logro conseguido es importante conocer que cuando comenzó la temporada el presupuesto del que disponía (42 millones de dólares) era tres veces inferior al de los Yankees de Nueva York, el equipo más rico. El equipo de Oakland demostró que es más importante invertir bien el dinero que posees, que tener un alto presupuesto. (Lewis, 2004)

Para Beane, los conocimientos en materia de fichajes eran erróneos, ya que se basaban demasiado en suposiciones que no estaban sustentadas en números. Aunque los ojeadores usaban datos objetivos como la velocidad de los pies, ser hábil bateando bolas o la fuerza de los brazos, también había un componente

subjetivo en el que los buscadores esperaban una mejoría futura del jugador por el simple hecho de su similitud con algún profesional o por su corta edad. De la misma forma, se descartaban jugadores por una mala apariencia o una técnica rara de jugar, aunque fuera efectiva. Por eso, el CEO de los A's dejó claro a su equipo de ojeadores, que quería fijarse en jugadores que tuvieran experiencia a nivel universitario, ya que los datos serían más objetivos. Con este método dejarían de especular y podrían valorar los logros reales de cada uno en el terreno de juego (Hakes & Sauer, 2006, pág 173-186).

Por ejemplo, uno de los porcentajes más utilizados por los equipos profesionales para fichar, hasta ese momento, era el porcentaje de bateo. Sin embargo, Beane descubrió que era tres veces más importante la capacidad de un jugador para llegar a la base, que su porcentaje de bateo. Otro de los valores muy cotizados en el momento, era el robo agresivo de bases, pero tras analizar esta cualidad se dio cuenta de que ese porcentaje debía ser mínimo de un 70% para que fuera efectivo. Estos son algunos de los cambios que introdujo en su manera de seleccionar jugadores, unas ideas que fueron criticadas en su momento, pero que acabaron por darle la razón. Uno de los casos más polémicos y llamativos fue cuando se produjo el fichaje de Jeremy Brown, procedente de la Universidad de Alabama. El receptor fue ignorado en el draft del año 2002 por tener una fisionomía poco común para un jugador de béisbol. Los Atléticos de Oakland decidieron acometer su fichaje a pesar de las objeciones de todos los "entendidos". Brown finalizó la temporada como titular con unos números espectaculares. Tuvo un promedio de bateo de 0,310, un porcentaje de bases de 0,444 y un porcentaje de bateo de 0,545, anotando 40 carreras en sus primeros 55 partidos (Hakes & Sauer, 2006, pág 173-186).

Estos son algunos ejemplos de las técnicas mediante las que Beane, consiguió aprovechar las cualidades de jugadores menos valorados, pero que eran igual o más efectivos que otros con mayor valor. De esta manera el gerente general consiguió hacer un uso más eficaz de sus recursos que otros equipos con presupuestos más elevados.

4.2 La evolución del baloncesto según Mathu Alagappan

Muthu Alagappan nació en 1990 en Crewe, Inglaterra. A pesar de su lugar de nacimiento se crió en Texas y realizó sus estudios en la universidad americana de Stanford. Durante su etapa de estudiante realizó prácticas en una empresa de Big Data de reciente creación, llamada Ayasdi. Esta compañía poseía un software de estadísticas de baloncesto, que Muthu utilizó para su teoría acerca de las nuevas posiciones. (Muthu Alagappan, n.d.)

Tradicionalmente este deporte concebía la existencia de 5 posiciones: base, escolta, alero, ala-pivot y pivot. El inglés consideraba que en el baloncesto las posiciones debían describir cómo jugaba cada jugador, y que no fuera la posición la que determinara su forma de jugar. Por esa razón creó 13 posiciones en función de las cualidades de los jugadores de la NBA. Esta teoría se basaba en los datos y estadísticas, ya que en función de ellos cada jugador tendría una posición. Sin embargo, el método tradicional asignaba una posición a un jugador en función de la altura y el peso. En el año 2012 presentó sus descubrimientos en el congreso del MIT Sloan Sports Analytics, y llamó la atención de varios equipos de la NBA que comenzaron a trabajar con ese software (Muthu Alagappan, n.d.).

Las posiciones creadas por Alagappan fueron las siguientes: (Beckham, 2012)

- Offensive Ball- Handler: Jugadores con manejo de balón y especializados en puntos, tiros libres y tiros intentados, pero por debajo de la media en bloqueos y robos. Algunos ejemplos son Jason Terry y Tony Parker.
- Defensive Ball-Handler: Jugadores con mentalidad defensiva, con buen manejo de balón. Son especialistas en robar y asistir, pero no son buenos anotadores, como Mike Conley y Kyle Lowry
- Combo Ball-Handler: Jugadores hábiles en defensa y en ataque, pero no son especialistas en ninguna. Algunos ejemplos son Jameer Nelson y John Wall.

- Shooting Ball-Handler: Un jugador que tiene un don para anotar puntos, está por encima de la media, como Stephen Curry y Manu Ginobili.
- Role-Playing Ball- Handler: Jugadores con pocos minutos y que no tienen un gran impacto estadístico como Arron Afflalo y Rudy Fernández.
- 3 point Rebounder: Es un jugador que maneja el balón y está por encima de la media en rebotes y en triples, tanto intentados como realizados, en comparación con los que manejan el balón. Luol Deng y Chase Budinger pertenecen a esta categoría.
- Scoring Rebounder: Jugador que coge el balón con frecuencia y exige atención cuando está en ataque. Dirk Nowitzki y LaMarcus Aldridge juegan en esta posición.
- Paint Protector: Jugadores de envergadura que destacan por bloquear tiros y conseguir rebotes, y que acumulan más faltas que puntos. Ejemplos como Marcus Camby y Tyson Chandler.
- Scoring Paint Protector: estos jugadores destacan en ataque y en defensa, anotando, reboteando y bloqueando tiros. Kevin Love y Blake Griffin son algunos ejemplos.
- NBA 1st Team: Son jugadores tan superiores a la media en todas las categorías estadísticas que el software simplemente los agrupa sin tener en cuenta su altura o peso. Lebron James o Kevin Durant.
- NBA 2nd Team: Jugadores un poco inferiores como los del primer equipo, pero siguen siendo grandes jugadores. Rudy Gay o Caron Butler.
- Role Player: No juegan muchos minutos y tienen menos nivel que los del segundo equipo. Tipos como Shane Battier y Ronnie Brewer entran en esta posición.

- One of a kind: tan buenos que se salen de lo normal. Derrick Rose o Dwight Howard.

El objetivo de este estudio era el de cambiar la forma de pensar de los equipos a la hora de construir las plantillas. De esta manera se podían construir equipos basados en los datos y desarrollar estilos de juego mucho más concretos. Además su aplicación puede servir tanto al entrenador, como al manager. El entrenador puede analizar las estadísticas y cambiar la preparación de un partido. En el caso del manager le permite descubrir jugadores de un gran rendimiento con poco coste.

4.3 El impacto del saque en el tenis

El tenis es un deporte en el que existen una serie de patrones de movimientos complejos. Además debemos de tener en cuenta que el objetivo de un tenista es ganar, y para ello debe demostrar cualidades como la versatilidad y adaptabilidad a múltiples aspectos inherentes al juego, como el tiempo de recuperación entre golpes o el equilibrio. Hay que añadir que factores como la reducción del tiempo entre torneos, o el aumento de la velocidad de las bolas han hecho que deban modificarse los métodos de entrenamiento. (Bacic & Hume, 2018)

El estudio que exponemos a continuación analiza a través de los datos registrados en partidos de torneos de élite entre 2003 y 2008, diversos aspectos referentes al saque y su importancia en el juego. Para ello se evaluó la influencia de factores como la velocidad del saque, su ubicación, la superficie sobre la que se jugaba, las diferencias de género y la intensidad del efecto en los saques. (Mecheri et al., 2016)

Los sistemas conocidos “ojo de halcón” o Hawkeye son los que permiten recabar toda la información recogida en este análisis. Este sistema ha supuesto una revolución en el mundo del tenis, no sólo por su conocido uso de comprobar si una bola ha tocado la línea o no, sino porque los entrenadores pueden aplicar estos conocimientos para la revisión de datos. Incluso gracias a esta tecnología las televisiones pueden poner al servicio del espectador, un cuadro de estadísticas del encuentro que están viendo.

El Hawk-eye consiste en un conjunto de diez cámaras de alta velocidad colocadas alrededor de la pista, y un algoritmo muy sofisticado permite seguir la pelota a lo largo de cada jugada con un error estimado de 3.6 mm (Mecheri et al., 2016).

4.3.1 Qué se analiza durante el seguimiento

El estudio quiso examinar las relaciones entre varias características del saque, resumidas en la relación entre la trayectoria de la pelota y las posibilidades del punto ganador. Las características o variables que se incluyen son la velocidad del saque, el tipo de efecto del saque o la superficie sobre la que se está jugando.

Uno de los objetivos era el de demostrar que éste método era efectivo para analizar las estrategias de saque durante los partidos, comparando los resultados con los de los estudios de anotación. También se quería evaluar la relación existente entre la intensidad del efecto y las probabilidades de conseguir el punto tanto con el primer como con el segundo servicio. Por último se examinó la influencia de factores como la velocidad del saque, el sexo, la superficie de la pista o la tasa de puntos ganadores. Se analizó la posición del impacto del saque en función del rango (primero, segundo) y del lado (pista de deuce, pista de ventaja) para hombres y mujeres (Mecheri et al., 2016).

La investigación ratifica que en el mundo del tenis la superficie de la pista, tiene influencia en el juego, y por tanto en el resultado. Las diferentes superficies han afectado a la importancia de los primeros saques. Según éste, surgen 2 categorías de superficie en función del impacto del saque: las pistas rápidas (hierba e indoor) y pistas lentas (tierra y dura).

Los resultados reflejan que el primer saque tiene una mayor influencia en la victoria en las pistas rápidas, y es similar entre las lentas, es decir, tiene una importancia parecida en tierra y pista dura. Este último dato es sorprendente ya que siempre se ha pensado que la tierra batida, al tener un mayor coeficiente de fricción le da al receptor una mayor oportunidad de devolver el saque, por lo que su importancia será inferior que en una dura. (Mecheri et al., 2016)

Y es que cada tipo de superficie demanda un patrón y un estilo de juego diferente. Por ejemplo, al comparar las finales de Roland Garros (tierra batida) y Wimbledon (hierba) del año 2000 se obtuvieron los siguientes datos:

En Wimbledon el 97% de los puntos terminaron en cinco golpes o menos (peloteos cortos) mientras que en Roland Garros el 61% fueron peloteos cortos, el 22% regulares (entre 6 y 9 golpes) y el 17% fueron peloteos largos, es decir, con más de 9 golpes.

También se demostró que el saque y su devolución, son los golpes más decisivos para ganar en hierba, mientras que en la arcilla es mucho más importante un buen juego de fondo de pista. (Mecheri et al., 2016)

4.3.2 El impacto del primer y el segundo servicio

Con este análisis también se buscaba explicar la diferencia en la influencia de jugar con primer o segundo saque. Éste estudio se hizo tanto para hombres como para mujeres, lo que nos permitía explicar la diferencia en el perfil del punto entre ambos géneros, en lo que se refiere a duración y número de golpes del rally.

Los datos demuestran que los jugadores masculinos sacan más rápido y ganan más puntos que las jugadoras, pero tienen un peor porcentaje de primeros servicios. Con el segundo saque, las mujeres sacan más lento que los hombres y meten menos servicios. Esto se debe a que los jugadores sacan de una forma más plana, lo que les permite hacer más aces y devoluciones, mientras que las jugadoras basan su juego en golpes de fondo de pista, en la mayoría de los puntos (Mecheri et al., 2016).

4.3.3 La influencia de la velocidad del servicio

En el análisis encontramos una influencia en la velocidad del saque sobre el porcentaje de victorias. En el estudio se afirma que “realizar un primer saque “duro” es una estrategia de saque ganadora para conseguir un alto porcentaje de puntos y aumentar las posibilidades de ganar puntos con el segundo saque . Los saques rápidos aumentan las limitaciones de tiempo en los receptores al reducir el tiempo

disponible para ejecutar su tiro y dificultar el control de la pelota”. (Mecheri et al., 2016)

4.3.4 La relación entre el número de golpes y el porcentaje de puntos ganados




Tabla 1. Porcentajes de servicios (Mecheri et al., 2016).

En las gráficas que exponemos a continuación encontramos una relación inversamente proporcional entre el número de golpes por punto, y el porcentaje de ganancias con primer saque, tanto en hombres como en mujeres. Esto quiere decir que la influencia del saque es mayor cuando menos golpes hay, por lo que los puntos con un número bajo de golpes favorecen a los sacadores.

Si hablamos de los segundos saques, la relación entre el número de golpes y el porcentaje de servicios ganados es muy bajo, debido a que las limitaciones del restador son menores en los segundos saques. En este caso no puede atribuirse los puntos a la calidad del saque sino a la calidad de la devolución (Mecheri et al., 2016).

La utilidad que quieren darle los creadores de este documento es la de animar a los profesionales del mundo del deporte al uso de tecnologías avanzadas de datos para comprender y estudiar el rendimiento y comportamiento de los jugadores. Los datos que he expuesto son sólo los que he considerado más relevantes y significativos de este estudio, ya que pueden dar un gran volumen de información útil al entrenador y al propio jugador acerca del juego.

5. Big Data y análisis de datos en el mundo del fútbol

Previamente hemos visto las diferentes aplicaciones que tiene el Big Data y su análisis en otros deportes y cómo su aplicación ha supuesto diferentes casos de éxito en las últimas décadas.

El fútbol, en concreto, ha sido una de las últimas disciplinas deportivas en adquirir esta tecnología, y cada día son más los equipos que incorporan el análisis de datos a sus modelos de club.

Una de las razones por las que el fútbol se ha incorporado tan tarde es la importancia que se le ha otorgado siempre a la improvisación y el talento, unas aptitudes que son difíciles de cuantificar y que han hecho que históricamente muchos profesionales del gremio hayan sido reacios a incorporar la ciencia como herramienta (Big Data En El Fútbol ¿Cómo Se Aplica En Este Deporte?, n.d.). Más allá de que siempre hay gente contraria a romper con la monotonía, es cierto que el fútbol tiene unas características que dificultan la función de los profesionales de datos.

En este deporte juegan 22 jugadores en un terreno de juego de grandes dimensiones, por lo que hay muchas tomas de decisiones y factores que influyen. Además el modelo de anotación hace que sólo se vean 2 o 3 goles en partidos normales, incluso se puede empatar, algo que no ocurre en otras disciplinas como el baloncesto.

El director deportivo del Sevilla, Ramón Rodríguez Verdejo “Monchi” (San Fernando, Cádiz, 20 de septiembre de 1968) es considerado uno de los pioneros en el fútbol español en hacer uso de la tecnología Big Data y el análisis de datos, además de uno de los directores deportivos con mejor reputación en el mundo del fútbol.

Por esta razón hemos seleccionado una carpeta de videos publicados por el Sevilla FC en su canal de Youtube, para explicar cuáles son los apartados en los que más relevancia tiene la información obtenida de los datos (Sevilla FC, 2020).

Aunque son muy variados los usos que podemos hacer de esta tecnología, los equipos de fútbol actualmente demandan el uso de profesionales del análisis de datos en la prevención de lesiones, el scouting y en el fichaje de jugadores.

5.1 Prevención de lesiones

El mundo del deporte y de la alta competición especialmente, comporta un riesgo considerable a la hora de poder sufrir una lesión, debido a su alto nivel de exigencia. Esta exigencia tan elevada nos lleva a un sobreuso de los grupos musculares, o a someter a niveles de estrés a nuestros huesos y músculos, que pueden derivar en un aumento del riesgo de lesión.

Para poder ejemplificar la cantidad de ausencias por esta causa que existen en el mundo del fútbol se considera que hay una media de 9 lesionados por cada 1000 horas de juego, incluyendo entrenamientos, lo que equivaldría en el mundo laboral a que una empresa tuviera 9 trabajadores de baja por semana. Es de sobra conocido que en todos los deportes a un nivel alto entran en juego muchos temas e intereses extradeportivos. La lesión de un jugador no es importante sólo a nivel personal, por que pueda perjudicar su carrera, sino porque también puede repercutir en los resultados del equipo durante la temporada o suponer un mayor gasto económico para el club. Estas son algunas de las razones que han llevado a los equipos de fútbol a darle cada vez más importancia a este aspecto. (Cos et al., 2010, pág 98-99)

Desde la década de los años 80, existen múltiples estudios epidemiológicos que han intentado describir las características de las lesiones. Entre los años 1999 y 2000 la UEFA (Union of European Football Associations) elaboró un documento con diferentes recomendaciones que se ha ido completando con el paso de los años. Es importante aclarar que cada club de fútbol elabora su propio modelo pero estas pautas han sido y son, referentes en la búsqueda de diseños de protocolos para prevenir lesiones.

El modelo elaborado por la UEFA recoge un periodo de estudio que abarca tanto la temporada que se está jugando como su período de preparación, la pretemporada. Para poder realizar un estudio de cada jugador este modelo propone la creación de tres formularios que permitan recoger la suficiente información.

A. Formulario Base (Cos et al., 2010, pág 99)

En él se recoge información referente tanto al historial médico como a los datos antropométricos del jugador. Estos son los datos que debería incluir:

- Peso
- Altura
- Pierna dominante
- Historial de lesiones y/u operaciones

Además dentro de este modelo existe una segunda parte que requiere del consentimiento del jugador, en él aparecen datos como:

- Condiciones goniométricas (rango de movimiento de una articulación)
- Laxitud articular
- Resultados en test de condición física

En el siguiente ejemplo se muestran los datos resultantes de un test realizado a jugadores de élite del fútbol costarricense para medir sus características fisiológicas y antropométricas.

Hay que dejar claro previamente que los datos que aparecen no serían los idóneos ya que en el estudio UEFA, no se haría el análisis de manera conjunta sino a cada jugador, pero sí son correctas las secciones que aparecen.

	Total (n = 220)	Porteros (n = 23)	Defensas (n=57)	Mediocampistas (n=95)	Delanteros (n =45)
Peso (kg)	73,34 ± 7,34	78,86 ± 5,32a	74,6 ± 6,55ab	71,62 ± 7,64b	72,53 ± 7,06ab
Estatura (cm)	1,74 ± 5,74	1,78 ± 4,0 a	1,76 ± 5,40ab	1,72 ± 5,69b	1,74 ± 5,77ab
Grasa corporal (%)	9,78 ± 3,64	11,10 ± 2,85	9,84 ± 3,77	9,78 ± 3,74	9,03 ± 3,53
Peso magro (kg)	66,04 ± 5,93	70,02 ± 3,93	67,15 ± 5,26	64,49 ± 6,19	65,88 ± 5,90
Masa ósea (kg)	13,03 ± 0,48	13,31 ± 0,28	13,11 ± 0,62	12,89 ± 0,41	13,07 ± 0,41
Peso residual (kg)	17,67 ± 1,76	19,00 ± 1,28	17,97 ± 1,57	17,26 ± 1,84	17,48 ± 1,70
Masa muscular (kg)	35,34 ± 4,14	37,70 ± 2,74a	36,05 ± 3,80ab	34,35 ± 4,34b	35,32 ± 4,16ab
Salto vertical (cm)	32,65 ± 4,30	33,59 ± 3,50	33,30 ± 4,35	32,17 ± 4,45	32,36 ± 4,22
Salto contramovimiento (cm)	39,87 ± 4,81	41,13 ± 3,75	39,96 ± 4,32	39,40 ± 5,19	40,09 ± 5,07
Salto técnica (cm)	46,89 ± 5,30	47,13 ± 5,31	47,19 ± 5,19	46,35 ± 5,43	47,50 ± 5,25
Velocidad en 10m (m/s)	5,45 ± 0,86	5,24 ± 0,60	5,62 ± 0,86	5,44 ± 0,91	5,34 ± 0,84
Velocidad en 25m (m/s)	6,68 ± 0,54	6,53 ± 0,55	6,74 ± 0,53	6,70 ± 0,61	6,63 ± 0,31
Slalom con balón (m/s)	3,94 ± 0,26	3,98 ± 0,34	4,0 ± 0,24	3,88 ± 0,25	3,97 ± 0,24
Slalom sin balón (m/s)	4,36 ± 1,75	4,78 ± 1,83	3,88 ± 1,78	4,61 ± 1,76	4,25 ± 1,54
Índice de fatiga	0,80 ± 0,07	0,77 ± 0,07	0,80 ± 0,06	0,80 ± 0,06	0,79 ± 0,07
Agilidad (m/s)	1,66 ± 0,31	1,66 ± 0,26	1,76 ± 0,27	1,62 ± 0,35	1,63 ± 0,26

Tabla 2. Características antropométricas y fisiológicas de futbolistas de élite costarricense (Sánchez Ureña et al., n.d.)

B. Formulario de exposición y participación

En este listado están incluidos tanto los nombres como los dorsales de todos los jugadores. En él se irán anotando los minutos de participación de cada jugador tanto en entrenamientos como en partidos, de una manera semanal o mensual. Este formulario puede ser ampliado con datos como:

- Condiciones meteorológicas
- Superficie de juego (césped natural o artificial)
- Tipo de entrenamiento (fuerza, resistencia, velocidad...)

C. Formulario de lesión

Este último debe recoger toda la información posible acerca de las lesiones. Por esa razón debe incluir datos como:

- Fecha de lesión
- Si ha sido producida en un partido o en una sesión de entrenamiento
- Tipo de lesión
- Localización
- Gravedad

Además en los días o semanas posteriores se debe ampliar esta información con datos acerca de si se ha producido por un contacto o no, la superficie de juego sobre la que se estaba jugando, o el mecanismo lesional.

Una vez realizados los tres formularios a cada uno de los jugadores a lo largo de una temporada, el club puede comparar tanto a nivel individual como grupal los datos de diferentes años para analizar la efectividad de sus métodos preventivos.

Temporadas	2003-04	2004-05	2005-06	2006-07
Número total de lesiones	63	44	31	37
Lesiones/1.000 h de exposición al entrenamiento	7	3	3	3
Lesiones/1.000 h de exposición a la competición	34	25	15	15
Lesiones musculares	22	6	14	14
Lesiones musculares leves (<1 semana)	8	2	2	3
Lesiones musculares moderadas (1-4 semanas)	11	4	10	8
Lesiones musculares graves (>1 mes)	3	0	2	3
% lesiones musculares/total de lesiones	35	14	45	33
Total de horas de exposición del equipo	5.655	6.458	5.719	7.561
Lesiones musculares/1.000 h de exposición	4	1	2	2
Lesiones musculares/1.000 h de partido	16	5	9	12
Lesiones musculares/1.000 h de entrenamiento	1,7	0,2	0,7	2,2
Total de días de baja	952	1.404	657	685
Días de baja por lesión muscular	317	84	264	324
Entrenamientos perdidos por lesión muscular	203	46	173	186
Partidos perdidos por lesión muscular	58	17	59	51

Tabla 3. Incidencia lesional en el primer equipo del Fútbol Club Barcelona durante cuatro temporadas consecutivas (Servicios Médicos del Fútbol Club Barcelona, 2009).

Esta tabla arroja una gran cantidad de información muy útil para entender la importancia de una buena metodología en cuánto a la prevención de lesiones se refiere. El club catalán ha ido mejorando sus datos tal y como se refleja en el número total de lesiones, que se ha ido reduciendo. En la temporada 2006/2007 hubo 6 lesionados más que en la temporada 2005/2006 pero también los jugadores se vieron expuestos a casi dos mil horas más de partidos y entrenamientos. También vemos que a nivel muscular se han ido reduciendo los días de baja por lesión, pero han aumentado las lesiones musculares, lo que implica que el club debe mejorar sus técnicas de prevención de lesiones musculares para adaptarla al aumento de tiempo de exposición de sus jugadores.

5.2 Scouting

Éste término, muy utilizado en el mundo del deporte hoy en día, se ha postulado como una actividad imprescindible para cualquier cuerpo técnico. Hasta hace no mucho, la toma de decisiones de directivos y entrenadores se basaba en su experiencia e intuición, ahora estas actividades tienen una base sólida y fiable, gracias al scouting y a las grandes cantidades de datos que se manejan en el mundo del deporte actualmente (MBP School of Coaches, 2018).

El scouting es un proceso que nos permite analizar a jugadores y equipos, tanto propios como externos, en partidos y entrenamientos para extraer toda la información posible sobre ellos. La persona que realiza esta función recibe el nombre de scout o analista, y tiene las siguientes características (MBP School of Coaches, 2018):

- Tener una visión completa del fútbol a nivel técnico, táctico, condicional...
- Debe poseer un conocimiento del modelo de juego que quiere el entrenador, el club y el modelo de competición para poder diferenciar entre lo que le interesa, y lo que no.
- Tiene que tener una buena capacidad comunicativa para transmitir esa información de la mejor manera.
- Es importante que el “scout” o analista tenga destrezas y capacidades suficientes que le permitan recoger toda la información y ordenarla de forma informatizada, y a la vez ser capaz de interpretarla y analizarla.

Para poder ejemplificar cómo trabajan los analistas de un equipo hemos usado los conocimientos adquiridos tras la lectura del artículo Visualizing a Teams Goal (Whitaker et al., 2018). En este artículo los autores exponen un estudio realizado en la Premier League Inglesa, durante la temporada 2016/2017. Los datos expuestos pertenecen a los analistas de la compañía Stratagem Technologies, una empresa londinense de tecnología financiera fundada en el año 2012.

Mediante la presentación y explicación de una serie de ejemplos vamos a intentar explicar cómo el departamento de scouting de un club, selecciona los datos y elige cómo puede interpretarlos para darles una utilidad en el terreno de juego.




Figura 2. Mapa de asistencias de Christian Eriksen en la Premier League durante la temporada 16/17 (Whitaker et al., 2018, pág 282)

El primer ejemplo muestra diferentes ubicaciones en las que el jugador danés, Christian Eriksen daba las asistencias en función del momento del partido.


A pesar de que se podría conocer este dato de todos los jugadores de la plantilla del Tottenham Hotspur (equipo en el que militaba ese jugador) durante esa temporada no tendría sentido hacerlo, ya que no serían relevantes las zonas dónde un central o un portero tocan el balón. Por eso es tan importante que la persona encargada de analizar sepa que este jugador es el más creativo de su equipo y que es determinante en los metros finales por su gran capacidad para asistir y su buen golpeo desde media distancia.

Como hemos explicado previamente, hay que poseer conocimientos en materias como matemáticas y estadística, para poder seleccionar los modelos mediante los que se van a tomar los datos. En la figura vemos como hay coordenadas para ubicar cada punto de manera exacta. El eje OX mide el ancho del campo, y el eje OY mide el largo. El cuadro recoge además 6 partes debido a que los 90 minutos de un partido los dividen en partes de 15 minutos. Por último, tal y como indica la leyenda de la figura, a más claro es el color más balones toca el jugador para asistir o disparar y por el contrario, a más oscuro, menos.

Esta información debe sumarse a que el club londinense jugaba con un esquema 1-4-3-3, dónde Eriksen ocupaba la posición de interior derecho. Eso explica el T-1, ya que tiene un posicionamiento más estático en el margen derecho y no se mueve tanto por otras zonas. El T-2 indica que entre el minuto 15 y 30 el Tottenham suele lanzar muchos córners, ya que Eriksen es el encargado de lanzarlos y como se ve en el gráfico, se destacan esas zonas. En el T-3 parece dar pocas asistencias ya que no tiene una gran incidencia en ninguna de las zonas.

En el T-4, al inicio de la segunda parte, el danés se muestra muy peligroso realizando acciones de asistir o disparar desde casi cualquier altura de la banda derecha o el centro. En el T-5 su influencia pasa a la zona centro, probablemente se deba a un cambio de posición que le permita estar más cerca del área.

Finalmente en el último tramo de 15 minutos casi no aparece. Es posible que aquí influya el hecho de que en estos minutos el juego de su equipo, tanto a nivel defensivo como ofensivo, es mucho más directo y físico, algo que no beneficia a un jugador de sus características.



Figuras 3 y 4. Zonas de asistencia de Riyad Mahrez en la Premier League durante la temporada 16/17 (Whitaker et al., 2018, pág 283-284)

El segundo ejemplo corresponde a los lugares en los que Riyad Mahrez (Leicester City) asistió a un compañero en diferentes períodos de la temporada . A pesar de que cada época del año que se refleja posee tres mapas de acción, cada uno con una ponderación ya que podemos ver que las de la fila superior se basan en el cuantil del 5%, las de la fila central en la media y las de la fila inferior en el cuantil del 95%. He seleccionado esta gráfica ya que los mismos datos pueden servir para cosas diferentes. En el anterior podíamos observar la evolución de la influencia de un jugador a lo largo de un partido, y en este caso podemos ver la evolución a lo largo de una temporada.

En la 2016-2017 Riyad Mahrez realizó una buena campaña, desempeñando un gran papel como asistente. Si conocemos un poco la actualidad del club, algo que deberíamos dar por supuesto si trabajamos para un equipo de fútbol, deberíamos saber que en el mes de febrero el Leicester sustituyó al entrenador Claudio Ranieri por Craig Shakespeare. Hasta la llegada del nuevo entrenador el futbolista argelino no jugaba en una posición, ni en un estilo de juego en el que pudiera explotar sus

cualidades. Esto se ve reflejado en las dos primeras ilustraciones donde su área de participación es muy pequeña. Sin embargo a partir del tercer mes podemos ver como su crecimiento es increíble y tiene incidencia tanto en la banda derecha (posición desde la que parte aún siendo zurdo) como en el centro.

Team	Block					
	t ₁	t ₂	t ₃	t ₄	t ₅	t ₆
AFC Bournemouth	-0.043	-0.004	-0.211	-0.231	-0.003	-0.075
Arsenal	0.043	0.122	0.238	0.201	0.086	0.150
Burnley	-0.098	-0.174	-0.280	-0.166	-0.178	-0.291
Chelsea	0.040	0.036	0.310	0.307	0.183	0.384
Crystal Palace	-0.0231	-0.079	-0.200	-0.106	-0.020	-0.126
Everton	-0.024	0.030	0.233	0.015	0.069	0.284
Hull	-0.143	-0.057	-0.304	-0.147	-0.183	-0.125
Leicester City	-0.058	-0.080	-0.303	-0.121	-0.139	-0.174
Liverpool	0.118	0.207	0.414	0.390	0.130	0.333
Manchester City	0.201	0.401	0.375	0.268	0.249	0.465
Manchester United	0.111	0.234	0.341	0.033	0.112	0.253
Middlesbrough	-0.065	-0.263	-0.255	-0.162	-0.208	-0.198
Southampton	0.092	0.075	0.090	0.132	0.020	0.091
Stoke City	-0.053	-0.182	-0.162	0.028	-0.081	-0.113
Sunderland	-0.296	-0.080	-0.200	-0.156	-0.194	-0.531
Swansea City	0.047	-0.139	-0.042	-0.093	-0.106	-0.236
Tottenham Hotspur	0.169	0.220	0.360	0.254	0.208	0.332
Watford	-0.095	-0.153	-0.189	-0.197	0.020	-0.211
West Bromwich Albion	-0.001	-0.183	-0.160	-0.171	-0.015	-0.138
West Ham United	0.077	0.071	-0.056	-0.076	0.051	-0.075

Tabla 4. Capacidad media de ocasión de gol por equipo de la Premier League en la temporada 16/17 (Whitaker et al., 2018, pág 280)

Por último, vamos a analizar una tabla en la que se muestra la capacidad media de cada equipo de la Premier League para generar ocasiones de gol. Los datos fueron recogidos a lo largo de la temporada 2016-2017, y vamos a ver como la información que se recoge siempre guarda una lógica con el desarrollo de cada equipo a lo largo de una campaña completa. Como se suele decir, los datos no mienten.

Cada una de las columnas indican periodos de 15 minutos, por lo que se divide el tiempo total de un partido de 90 minutos en seis secciones.

CLASIFICACIÓN	PUNTUACIÓN	GOLES A FAVOR	GOLES EN CONTRA
CHELSEA	93	85	33
TOTTENHAM	86	86	26
MAN.CITY	78	80	39

Tabla 5. Puntuaciones y estadísticas de los tres primeros clasificados de la Premier League en la temporada 16/17

El análisis de la información de la Tabla 4 nos muestra que “ los mejores equipos” en cuanto a la creación de ocasiones se refiere son el Tottenham, el Chelsea y el Manchester City, ya que poseen los valores más altos en la tabla. No es casualidad que en esa temporada los tres primeros clasificados fueran Chelsea (1º), Tottenham (2º) y Manchester City (3º). En los dos últimos bloques, T5 y T6, es dónde poseen los valores más altos en comparación al resto, lo que nos permite deducir que poseen una gran capacidad para marcar goles en los últimos 30 minutos de los partidos, una cualidad que se suele traducir en muchos puntos ya que se reduce mucho la capacidad de reacción de los equipos rivales.

El tercer clasificado es el que mejores datos arroja en la Tabla 1 de los tres y casualmente es el que menos puntos consiguió.

Por eso es importante la información de la Tabla 5 donde encontramos las puntuaciones y la relación entre goles marcados y encajados de los tres equipos. Esta información nos muestra que el City es el equipo que menos efectividad ha tenido en las áreas ya que es el que menos ha marcado y el que más goles ha encajado.

CLASIFICACIÓN	PUNTUACIÓN	GOLES A FAVOR	GOLES EN CONTRA
HULL CITY	34	37	80
MIDDLESBROUGH	28	27	53
SUNDERLAND	24	29	69

Tabla 6. Puntuaciones y estadísticas de los tres últimos clasificados de la Premier League en la temporada 16/17

En la Tabla 4 encontramos que los equipos que peores números arrojan en la creación de ocasiones son los tres últimos clasificados de esa campaña: Hull City (18°), Middlesbrough (19°) y Sunderland (20°). Todos ellos arrojan unos datos muy pobres en todos los tramos del partido, pero sobre todo en el T1 Y T6, lo que explica por qué son de los equipos menos goleadores de la liga.

La Tabla 6 explica su clasificación final ya que en una liga de 38 partidos, ninguno de los equipos ha conseguido tener una media de un gol por partido, si le añadimos que han encajado más de un tanto en contra de media por jornada, queda clara su posición final.

5.3 Fichaje de jugadores

El fichaje de jugadores siempre ha sido una de las facetas más atractivas de este deporte. El morbo de la compra y la venta de jugadores, la incertidumbre de ver cómo lo hará un jugador con otro equipo... Aunque nunca ha sido un área que fuera tomada en serio por los equipos y sus dirigentes, se ha profesionalizado.

Como es obvio cada equipo tiene sus métodos y no son públicos, por eso nos hemos basado en el modelo que se expone en el libro “Iniciación al análisis de datos y Big Data aplicado al fútbol” (Roldán & Blas, 2017, pág 153-161).

Tal y como se afirma “los modelos no dejan de ser algoritmos (fórmulas) que van a transformar datos cuantitativos y cualitativos en valores referenciales. Estos valores serán los que los diferentes estamentos del club deberán tener en cuenta a la hora de la toma de decisiones en diferentes ámbitos”.

Para que un modelo fuese completo debería tener al menos este índice. (Roldán & Blas, 2017, pág 153-161)

- Datos de nacimiento y nacionalidad

Deberían aparecer los datos relativos a la fecha y lugar de nacimiento de un jugador. También la nacionalidad o nacionalidades que posee. Son datos relevantes no sólo por saber la edad del jugador, sino también porque por ejemplo en España tan sólo se pueden tener 3 jugadores extracomunitarios, es decir, de fuera de la Unión Europea.

- Datos de situación familiar

Para los clubes es importante conocer datos de la vida privada de un jugador como si tiene pareja estable o no, si posee a sus padres con vida, o si tiene hijos. Aunque parezcan datos irrelevantes, suelen decir mucho de la estabilidad emocional de una persona, y un deportista de élite puede verse afectado por esta causa y desarrollar lesiones o malas actitudes.

- Datos físicos

Altura, peso, color del pelo, o, pie dominante.

- Curriculum de formación académica

Nivel de estudios (E.S.O, Bachillerato, Universidad), colegios en los que ha estudiado o nivel de idiomas.

- Curriculum formativo en fútbol

Aquí debe aparecer el equipo y su categoría en las que ha estado el jugador a lo largo de todas las etapas formativas, es decir, desde el primer año de Alevín hasta el momento actual.

- Capacidades, habilidades y posiciones de juego

En lo que se refiere a las capacidades, se tienen en cuenta aspectos que no son fáciles de medir como, el liderazgo, el posicionamiento en el campo o la interpretación del juego.

En cuanto a las habilidades hablamos de datos cuantitativos sobre la aportación del futbolista en el campo como el porcentaje de duelos aéreos ganados, o el tanto por ciento de pases cortos, medios o largos acertados.

Por último se tienen en cuenta las diferentes posiciones en las que ha jugado un futbolista y la valoración media en sus participaciones.

- Internacionalidades

Número de internacionalidades con su selección desde el equipo sub-18 hasta la selección absoluta.

- Redes Sociales

Redes sociales en las que está presente el jugador, nombre de la cuenta y número de seguidores.

- Sentiment Analysis

Valoración en tanto por ciento de la calidad de esa cuenta (si es profesional o no, tipo de publicaciones o comentarios...).

- Impacto Mediático

Apariciones en SocialMedia, en medio online y offline y publicidad.

- Histórico de lesiones

Aquí se debe especificar el tipo de lesión, en qué temporada la sufrió, en que equipo se encontraba y el tiempo de recuperación que necesitó el jugador.

- Histórico de datos relacionados con partidos jugados

Porcentaje de partidos convocado y desconvocado por temporada, porcentaje de partidos jugados, media de tarjetas amarillas y rojas por temporada, porcentaje de partidos que se ha perdido el jugador por lesión, ratio de partidos ganados jugando como titular, ratio de puntos por partido jugado o porcentaje de titularidades, son algunos ejemplos.

- Histórico de objetivos

Media de pases por partido, porcentaje de pases correctos, media de balones recuperados, media de goles, media de kilómetros recorridos...

- Datos de la temporada en curso

Información del jugador durante esa temporada, respecto a sus titularidades, suplencias, media de pases, porcentaje de pases correctos...

- Trofeos individuales y colectivos

Los trofeos que ha ganado, la temporada en la que lo ha hecho y en qué equipo.

- Campeonatos de interés donde ha participado

La liga en la que ha jugado, nombre del equipo y temporada.

En este ejemplo aparecen muchos de los valores que los clubes consideran importantes actualmente. A pesar de que muchos de ellos parecen no guardar relación con lo que pueda ocurrir en el terreno de juego, los clubes les otorgan mucha importancia, y lo hacen debido a que los equipos y sus directivas quieren que los futbolistas sean activos que aporten algo más que rendimiento deportivo.

El director deportivo del Sevilla, Monchi, considera los datos como una ayuda a su trabajo, ya que le permite reducir el riesgo de equivocación y ganar tiempo. Si por ejemplo, tenemos una lista con datos sobre 1000 defensas centrales, y queremos fichar un jugador que tenga un gran juego aéreo, al poner como filtro un porcentaje alto de duelos aéreos ganados, se reducirá considerablemente la lista de jugadores. Si además seguimos filtrando los datos por variables, como la edad, el precio o la nacionalidad nos quedará un número muy reducido sobre el que trabajar (Sevilla FC, 2020).

6. Conclusión

Haciendo una síntesis de toda la información recogida queda claro que el Big Data es una tecnología que permite almacenar y procesar grandes volúmenes de información, que puede ser utilizada en múltiples ámbitos, desde los negocios al mundo del deporte. Pero tal y como hemos podido ver a lo largo del trabajo su gran impacto se debe a que en los últimos 30 años se han desarrollado herramientas que han permitido que esos datos se conviertan en información útil. Es decir, sin científicos y analistas simplemente existirían miles de datos que no podrían aportar nada.

En lo que se refiere a su aplicación al mundo deportivo creo que sería un error no aprovechar las múltiples utilidades que nos ofrece esta tecnología. Gracias al Big Data los clubes, jugadores y entrenadores obtienen una información muy valiosa que puede otorgarles una ventaja competitiva sobre sus competidores. Aunque en mi opinión, sería una gran equivocación basar todo en el análisis de datos ya que si algo hemos aprendido a lo largo de la historia del deporte, es que el talento y la improvisación siguen siendo determinantes en la consecución de grandes gestas, y que por mucho que una máquina pueda darnos una predicción de un resultado, no quiere decir que sepa lo que va a ocurrir.

Creo que debemos aceptar que los avances tecnológicos han llegado para quedarse, y debemos cederles su espacio de trabajo y tomarlos como una ayuda.

7. Bibliografía

- Analista de datos y Científico de datos: Diferencias y habilidades* | Tecon. (2022, January 24). Tecon Soluciones Informáticas. Retrieved November 9, 2022, from <https://www.tecon.es/analista-de-datos-y-cientifico-de-datos-diferencias-y-habilidades/>
- Batistic, S., & van der Laken, P. (2019). History, Evolution and Future of Big Data and Analytics: A Bibliometric Analysis of Its Relationship to Performance in Organizations. *British Journal Management*, 30, 229-251.
- Dean, J., & Ghemawat, S. (2008). MapReduce: simplified data processing on large clusters. *Communications of the ACM*, 51(1), 107-113. <https://doi.org/10.1145/1327452.1327492>
- Diferencias entre un científico de datos y un analista de datos* | 2022. (n.d.). Máster en Data Science. Retrieved November 9, 2022, from <https://masterdatascienceceupe.com/diferencias-entre-un-cientifico-de-datos-y-un-analista-de-datos/>
- Dumbil, E. (2013). A Revolution That Will Transform How We Live, Work, and Think: An Interview with the Authors of Big Data. *Mary Ann Liebert, Inc*, 1(2), 73-77. <https://doi.org/10.1089/big.2013.0016>
- Hopkins, B. (n.d.). Beyond the Hype of Big Data. *CIO*. <https://www.cio.com/article/284795/data-management-beyond-the-hype-of-big-data.html>
- Jeff Dean. (n.d.). Wikipedia. Retrieved November 9, 2022, from https://en.wikipedia.org/wiki/Jeff_Dean
- Jones, H. (2019). *Ciencia de los datos: La guía definitiva sobre análisis de datos, minería de datos, almacenamiento de datos, visualización de datos, Big Data para empresas y aprendizaje automático para principiantes*. INDEPENDENTLY PUBLISHED.
- Lago, C. (2018). 150 years of Business Intelligence: A brief history. *CIO*. <https://www.cio.com/article/221963/history-of-business-intelligence.html>
- Niño, M., & Illaramendi, A. (2015). Entendiendo el Big Data: Antecedentes, origen y desarrollo posterior. *DYNA New Technologies*, 2(1), 8.

- <https://www.dyna-newtech.com/busqueda-NT/entendiendo-big-data-antecedentes-origen-y-desarrollo-posterior>
- Roldán, J., & Blas, I. (2017). *Iniciación Al análisis de Datos y Big Data Aplicado Al Fútbol: El Fútbol Es un Juego*. CreateSpace Independent Publishing Platform.
- Sanjay Ghemawat. (n.d.). Wikipedia. Retrieved November 9, 2022, from https://en.wikipedia.org/wiki/Sanjay_Ghemawat
- VASS Team. (2018). Data Mining, el gran impulso del Big Data. VASS. <https://vasscompany.com/data-mining-el-gran-impulso-del-big-data/>
- Assunção, R., & Pelechrinis, K. (2018). Sports Analytics in the Era of Big Data: Moving Toward the Next Frontier. *Mary Ann Liebert, Inc.*, 6(4), 237-238.
- Bacic, B., & Hume, P. A. (2018). Computational Intelligence for Qualitative Coaching Diagnostics: Automated Assessment of Tennis Swings to Improve Performance and Safety. *Mary Ann Liebert, Inc.*, 6(4), 28. <https://doi.org/10.1089/big.2018.0062>
- Beckham, J. (2012, April 30). *Analytics Reveal 13 New Basketball Positions*. WIRED. Retrieved November 9, 2022, from <https://www.wired.com/2012/04/analytics-basketball/>
- Davenport, T. H. (2014). *Analytics in sports: The new science of winning*. Readkong. <https://www.readkong.com/page/analytics-in-sports-the-new-science-of-winning-6739419>
- Hakes, J. K., & Sauer, R. D. (2006). An Economic Evaluation of the Moneyball Hypothesis. *American Economic Association*, 20(3), 173-186. <http://www.jstor.org/stable/30033672?origin=JSTOR-pdf>
- Hughes, M., & Franks, I. M. (Eds.). (2004). *Notational Analysis of Sport: Systems for Better Coaching and Performance in Sport*. Routledge. <https://www.routledge.com/Notational-Analysis-of-Sport-Systems-for-Better-Coaching-and-Performance/Franks-Hughes/p/book/9780415290050>
- Lewis, M. (2004). *Moneyball: The Art of Winning an Unfair Game*. W. W. Norton.
- Mecheri, S., Mantel, B., Rioult, F., Kauffmann, F., & Benguigui, N. (2016). *The Serve Impact in Tennis: First Large-Scale Study of Big Hawk-Eye Data*. Wiley Online Library. <https://onlinelibrary.wiley.com/doi/10.1002/sam.11316>
- Muthu Alagappan. (n.d.). Wikipedia. Retrieved November 9, 2022, from https://en.wikipedia.org/wiki/Muthu_Alagappan

- Reep, C., & Benjamin, B. (1968). Skill and Chance in Association Football. *Wiley*, 131(4), 581-585. <http://www.jstor.org/stable/2343726?origin=JSTOR-pdf>
- Society for American Baseball Research*. (n.d.). Wikipedia. Retrieved November 9, 2022, from https://en.wikipedia.org/wiki/Society_for_American_Baseball_Research
- Big Data en el fútbol ¿Cómo se aplica en este Deporte?* (n.d.). CICE. Retrieved November 9, 2022, from <https://www.cice.es/blog/articulos/big-data-futbol/>
- Cos, F., Cos, M. A., Buenaventura, L., Pruna, R., & Ekstrand, J. (2010). Modelos de análisis para la prevención de lesiones en el deporte. Estudio epidemiológico de lesiones: el modelo Union of European Football Associations en el fútbol. *Apunts*, 45(166), 95-102. <https://www.sciencedirect.com/science/article/abs/pii/S188665811000023X?via%3Dihub>
- MBP School of Coaches. (2018). *El Scouting en el fútbol de alto rendimiento*. MBP School of Coaches. <https://mbpschool.com/scouting-en-el-futbol-de-alto-rendimiento/#:~:text=El%20scouting%20es%20el%20proceso,mejorar%20o%20potenciar%20su%20rendimiento>
- Sánchez Ureña, B., Ureña Bonilla, P., Salas Cabrera, J., Blanco Romero, L., & Araya Ramírez, F. (n.d.). *Perfil Antropométrico y Fisiológico en Futbolistas de Élite Costarricenses según posición de juego*. PubliCE. https://journal.onlineeducation.center/api-oas/v1/articles/sa-B57cfb27205da8/export-pdf/perfil-antropometrico-y-fisiologico-en-futbolistas-de-lite-costarricense-s-segun-posicion-de-juego-1382?_ga=2.142351026.1437582201.1667389027-1773467774.1667389027&_gl=1
- Servicios Médicos del Fútbol Club Barcelona. (2009). *Guía de Práctica Clínica de las lesiones musculares. Epidemiología, diagnóstico, tratamiento y prevención*. [apunts.org. https://www.apunts.org/en-pdf-X0213371709460323](https://www.apunts.org/en-pdf-X0213371709460323)
- Sevilla FC. (2020). *Monchi 13 Masterclass: Big Data XI*. youtube. <https://www.bing.com/videos/search?q=BIG+DATA+EN+EL+MUNDO+DEL+F%C3%9aTBOL&docid=607988960985050293&mid=90DC6E725358AF7E948B90DC6E725358AF7E948B&view=detail&FORM=VIRE>

Whitaker, G. A., Silva, R., & Edwards, D. (2018). Visualizing a Team's Goal Chances in Soccer from Attacking Events: A Bayesian Inference Approach. *Mary Ann Liebert, Inc.*, 6(4). <https://www.liebertpub.com/doi/10.1089/big.2018.0071>